

SI Research Discussion

志田浩太

July 17, 2026

- ▶ 非線形特徴選択に起因する選択バイアスとランダム選択の検証
- ▶ Importance Sampling & Adaptive Importance Sampling の勉強
- ▶ RF の Tree SHAP で選択された特徴量の選択領域の数値計算・可視化

Unadjusted vs. Random : 実験設定

グローバル帰無仮説

$$X_{ij} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1), \quad y_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1), \quad X \perp y, \quad \sigma^2 = 1 \text{ (既知)}.$$

- ▶ $n = 100, d = 20$, 選択数 $k = 1$
- ▶ 反復数 $R = 1000$, 有意水準 $\alpha = 0.05$
- ▶ Random Forest : 50 trees, max depth 5
- ▶ **Random** : y と独立に 1 特徴を選択
- ▶ **Unadjusted SHAP** : 平均絶対 SHAP 値が最大の特徴を選択

既知分散：カイ検定

選択特徴 j の B-spline 効果を表す正規直交基底を $Q_j \in \mathbb{R}^{n \times r}$ ($r = 3$) とする。


$$T_j = \frac{\|Q_j^\top y\|_2}{\sigma} = \|Q_j^\top y\|_2.$$

H_0 の下で、特徴 j があらかじめ固定されていれば

$$Q_j^\top y \sim \mathcal{N}_r(0, I_r) \implies T_j \sim \chi_r = \chi_3,$$

したがって $p_j = P(\chi_3 \geq T_j^{\text{obs}})$ と計算する。


結果：既知分散のカイ検定



Random
FPR = 0.056

**Unadjusted
SHAP**
FPR = 0.347

参考：未知分散の F 検定



Random
FPR = 0.060

**Unadjusted
SHAP**
FPR = 0.361

既知分散と同じ傾向を確認。

SHAP 選択領域の構成

1. 応答を 1 次元に制限する

$$P_j = Q_j Q_j^\top, \quad a_j = (I - P_j)y, \quad u_j = \frac{P_j y}{\|P_j y\|_2},$$
$$y(z) = a_j + u_j z, \quad z \geq 0 \quad (\sigma = 1).$$


2. 特徴 j が再び選ばれる範囲を求める

$$\mathcal{Z}_j = \left\{ z \geq 0 : j \in \hat{\mathcal{S}}_{\text{SHAP}}(X, y(z)) \right\}.$$

3. 選択を条件づける


H_0 下の $z \sim \chi_r$ を, $\mathcal{Z}_j$ 上で再正規化する。

SHAP selection regions : 全6データセット




SHAP selection regions : 代表例

Data set 3 (seed=303) | selected x_{17}
df=3, selection probability=0.8942



Data 3

Data set 4 (seed=404) | selected x_0
df=3, selection probability=0.3529



Data 4

 選択領域 $\mathcal{Z}_j$  条件付き分布  q_{final}  T_{obs}

選択領域はデータごとに異なる

Data	Seed	選択特徴	T_{obs}	$P(\mathcal{Z}_j)$	選択領域 ($z_{\text{max}} = 6.335$)
1	101	x_{14}	2.196	0.3319	[1.848, 6.335]
2	202	x_1	2.578	0.1838	[2.200, 6.335]
3	303	x_{17}	2.666	0.8942	[0.781, 6.335]
4	404	x_0	2.250	0.3529	[1.772, 1.862] $\cup$ [1.898, 6.335]
5	505	x_{18}	2.712	0.0964	[2.517, 6.335]
6	606	x_7	3.011	0.1506	[2.304, 6.335]

- ▶ $P(Z \in \mathcal{Z}_j) = \int_{\mathcal{Z}_j} f_{\chi_3}(z) dz$ は 0.096–0.894 と変動
- ▶ 全例で $T_{\text{obs}} \in \mathcal{Z}_j$
- ▶ Data 4 は選択領域が非連結
- ▶ 探索上限より右の無条件確率は約 10^{-8}